

Proyecto 2A: Segmentación de Imágenes con DeepLab-V3

Juan Macías Romero - 100472858

Manuel Andrés Trujillo - 100423448

Sofía Carmona Fuentes - 100475723

Visión Artificial - UC3M - 2025-2026

1. Experimentos e iteraciones

En esta sección explicaremos nuestro proceso de iteración donde hemos incrementado progresivamente las capacidades del modelo, la complejidad de las técnicas de entrenamiento y la dificultad de la tarea

EXP-01: Encoder-Decoder baseline

Entrenamos una red neuronal convolucional mínima desde cero para validar el pipeline. Jaccard 0.346: el modelo ignora más de la mitad de los edificios. La causa es que la Cross-Entropy Loss estándar aprende que predecir "fondo siempre" es más barato (el ~85% de píxeles son fondo). Los bordes de los edificios se predicen como manchas difusas, el típico caso en el que tiene sentido incorporar contexto local con skip connections.

EXP-02: U-Net + Weighted Loss

Incorporamos skip connections (arquitectura U-Net) y un peso $\times 5$ para la clase de edificio. El Jaccard subió a 0.427 y el recall mejoró notablemente. Aparece un problema nuevo: identificamos claros signos de overfitting desde la época 7, Val Jaccard alcanza su pico (0.422) y a partir de ahí oscila a la baja mientras Train Jaccard sigue creciendo hasta 0.615.

EXP-03: Focal Loss + Data Augmentation

Aplicamos data augmentation y Focal Loss para controlar el overfitting y concentrar el gradiente en los píxeles difíciles. El gap train/val baja de 0.225 a 0.073 y el recall alcanza el 82%. Sin embargo, el Jaccard apenas sube a 0.441. Pensamos que el cuello de botella ya no es el overfitting sino el contexto, y puede que con patches de 128 px el modelo no distinga tejados de carreteras.

EXP-04: DeepLabV3 R101 fine-tuning

Dimos el salto arquitectónico para solucionar el problema de capacidad del modelo. Al igual que en la anterior sección, hicimos un fine-tuning de DeepLabV3 con ResNet-101 preentrenado en COCO y patches de 512 px. El módulo ASPP captura contexto multi-escala y el backbone aporta representaciones ricas desde el inicio. Jaccard 0.494, sin overfitting adicional a pesar de los 60 M de parámetros. El problema cualitativo pendiente: el modelo fusiona edificios adyacentes en blobs sin separar instancias individuales.




Figura 1: Predicción del modelo EXP04 en una imagen del Huracán Florence al problema de segmentación binaria de edificios

EXP-05: Multiclase + ReduceLROnPlateau

Cambiamos de tarea de vuelta a la clasificación de 4 niveles de daño (no-damage, minor, major, destroyed). Sustituimos el scheduler coseno por ReduceLROnPlateau para evitar reducir el LR antes de que el modelo aprenda las clases raras, tras observar que el modelo seguía mejorando tras 30 épocas. El resultado fue muy malo: Jaccard medio 0.099, con minor, major y destroyed ignoradas por completo.

El desbalanceo es muy grande en el subconjunto de xBD usado (donde el 80% de los edificios son no-damage). La cantidad de píxeles pertenecientes a edificios dañados es realmente muy pequeña. La métrica de validación enmascaró el problema al promediar únicamente las clases presentes en cada batch. Fue en este paso que nos dimos cuenta de la diferencia en dificultad entre la segmentación de edificios, y la segmentación de edificios por tipo de desastre natural.

2. Modelo final y evaluación

EXP-06: ASPP[6,12,18] + aux loss + pesos agresivos

Hicimos 3 cambios simultáneos para atacar el desbalanceo y las limitaciones arquitectónicas:

- Probamos con pesos más agresivos $\alpha = [1, 4, 20, 30, 30]$ para forzar atención a las clases minoritarias.
- Probamos a reducir de las tasas del ASPP de [12, 24, 36] a [6, 12, 18]: las tasas por defecto generaban campos receptivos de 200–600 px, quizás demasiado grandes para edificios de 10–50 px. Pensamos que esto ayudaría a mejorar la compresión del modelo de la información local.
- También añadimos una pérdida auxiliar con peso $0.4\times$ sobre el aux_classifier, para llevar gradiente más profundo en el backbone durante las primeras épocas.

El entrenamiento fue de 40 épocas con Adam $lr=1e-4$ y ReduceLROnPlateau (factor=0.5, patience=4). El modelo alcanzó su pico en la época 27 (Val Jaccard = 0.287), tras la cual el scheduler redujo el LR tres veces sin recuperación apreciable, confirmando que la capacidad del modelo, no la tasa de aprendizaje, era el cuello de botella.

Nuestra evaluación principal consistió de calcular el Jaccard Index y las matrices de confusión (medias y por tipo de desastre natural) Ver Figuras 3 y 4 más adelante.

El label destroyed mejora $\times 5.5$ y minor $\times 4$, pero a costa de no-damage (-4.4 pp). El Jaccard medio fue 0.092. El desglose por tipo de desastre revela que el comportamiento del modelo no es uniforme, y en general bastante malo. Palu-tsunami es el único desastre donde el modelo detecta edificios destruidos con Jaccard apreciable (0.028, con imágenes individuales hasta 0.222). Los huracanes son el único tipo de desastre donde el modelo es capaz de predecir minor-damage (Jaccard ~ 0.01 – 0.05).

La matriz de confusión global refleja el sesgo estructural del modelo hacia las clases mayoritarias. La diagonal muestra que background y no-damage absorben la mayor parte de las predicciones: prácticamente todos los píxeles de minor, major y destroyed se predicen como no-damage o background. Los pocos aciertos en destroyed provienen casi exclusivamente de las imágenes de tsunami, donde la firma visual del daño es suficientemente distinta.

La figura 4 muestra los valores de activación de cada rama para cada rate. Al igual que lo que observamos en el problema de segmentación de objetos, aunque sí parecen codificar información espacial que ayuda a segmentar objetos distintos, todas las ramas presentan distribuciones parecidas y posiblemente redundantes. Esto indica que su objetivo, que es especializarse en contextos espaciales distintos (global vs local), no se está cumpliendo por alguna razón.

Nuestras conclusiones:

- La tarea de segmentación de edificios resulta mucho más sencilla que esa misma tarea con la dificultad añadida de clasificar el tipo de daño.
- El rebalanceo mediante la función de pérdida no resuelve un desbalanceo estructural. Esto también se trata de un problema de falta de datos.
- Al incrementar el tamaño de los patches, el tamaño del training set es más pequeño. Quizás tendría sentido añadir más transformaciones y más épocas, o elegir un subconjunto de xBD más grande.
- ASPP: Aprendimos que DeepLabV3 introduce average pooling 1x1 para aprender información no-espacial, del tipo “los edificios segmentados presentan daños”. Una posible dirección sería aumentar el número de parámetros dedicados a esto, quizás añadiendo más ramas de average pooling.
- Backbone: Es probable que la red pre-entrenada no contuviese información relevante para el análisis de daños en imágenes satelitales, por lo que quizás sería interesante hacer un fine-tuning más agresivo de esta red.




Figura 3: Matrices de confusión por desastre




Figura 4: Valores de activación por clase y por rama

Descripción de entregables:

- Código de cada experimento: results/parte-4/previous_experiments_code
- Notebook partes 1-3: APAI_Pr2A_ImageSegmentation_2025_2026.ipynb
- Notebook parte 4: APAI_Pr2A_ImageSegmentation_2025_202-part4.ipynb
- Full documentation of experiments: results/parte-4/[experiments.md](#)
- Repositorio: <https://github.com/macij1/cv-2a-image-segmentation>

División de trabajo:

- La primera parte del trabajo (partes 1-3) la realizamos todos para ganar el contexto necesario.
- Los primeros modelos básicos los entrenó Manuel Trujillo. La implementación de DeepLabV3 para el problema binario la realizó Sofía. Juan entrenó y evaluó el modelo final DeepLabV3 en la tarea de segmentación multiclase